Universidad de Buenos Aires – FIUBA – LSE

Aprendizaje Profundo – TP1

Cohorte 26 – 4to bimestre 2026

Alumno 1: Nombre y Apellido **Padrón:** _____
Alumno 2: Nombre y Apellido **Padrón:** _____
Alumno 3: Nombre y Apellido **Padrón:** _____

Pautas y Condiciones de Entrega

- Este primer TP comienza la semana de la clase 2 y la ventana de entrega estará abierta hasta las **23:59 hs del viernes 18 de septiembre (hora de Argentina)**.
- La resolución del TP puede realizarse de forma **individual, en parejas o hasta en grupos de 3 como máximo**. Sin embargo, no se recomienda repartir las preguntas entre los integrantes, sino que todos los integrantes deben trabajar conjuntamente en la resolución de cada pregunta para promover el debate, la discusión y la construcción de conclusiones compartidas.
- Pueden utilizar tanto los contenidos vistos en clase como bibliografía externa (debidamente citada con link o página de libro).
- **ESTE TP1 EQUIVALE A UN TERCIO DE SU NOTA FINAL.**
- El formato de entrega debe ser un link a un notebook de Google Colab. Es fundamental permitir acceso a `gvilcamiza.ext@fi.uba.ar` y **habilitar los comentarios** para recibir feedback.
- El desarrollo debe realizarse obligatoriamente en un notebook (`.ipynb`), ya sea en Colab o Jupyter local (subido a Google Drive). No se aceptarán scripts `.py` ni repositorios con múltiples archivos.
- El envío se realizará a través del formulario de Google Forms oficial. Tanto los resultados, tablas y gráficas, como el código y explicaciones deben quedar guardados y visualizables en el mismo notebook.
- Solo se revisarán los trabajos enviados mediante el formulario.

PREGUNTA 1 (Temas de la clase 1 y 2)

Comparación de Gradiente Descendente y Adam en una Función de Costo No Convexa

En este ejercicio se compararán los optimizadores **Gradiente Descendente (GD)** y **Adam** en la minimización de una función de costo basada en una red neuronal de una sola conexión sináptica:

$$z = wx + b$$

Con función de activación tangente hiperbólica:

$$\hat{y} = a(z) = \tanh(z) = \tanh(wx + b)$$

Se analizará la trayectoria de aprendizaje de ambos algoritmos y se evaluará su eficiencia con diferentes tasas de aprendizaje (*learning rate*).

La función de costo utilizada es el **Error Cuadrático Medio (MSE)**:

$$J(w, b) = \frac{1}{m} \sum_{i=1}^{m} (\hat{y}_i - y_i)^2$$

$$J(w, b) = \frac{1}{m} \sum_{i=1}^{m} (\tanh(wx_i + b) - y_i)^2$$

donde w y b son los parámetros que se busca optimizar.

Generación del Dataset Sintético

Para comparar los optimizadores se utilizará un dataset sintético unidimensional con la siguiente estructura:

```
x = np.linspace(ini, fin, n)
```

donde:

- x es un array de una dimensión con $n \geq 200$.
- El rango $[ini, fin]$ debe ser simétrico (por ejemplo: $[-3, 3]$, $[-5, 5]$, $[-1, 1]$, etc.).

El target y debe construirse como:

```
y = funcion_no_lineal(x) + ruido
```

donde:

- y es un vector 1D de tamaño n que sigue un patrón no lineal acotado entre -1 y 1 en el eje vertical, adicionando ruido mediante `np.random`.
- El patrón no lineal puede ser trigonométrico, exponencial, logarítmico, sigmoidal, polinómico de grado ≥ 3, o una combinación de estos (**recomendado**).
- **Restricción:** No elegir una función excesivamente compleja para que la red pueda converger, y no usar una función tanh pura (debe combinarse si se usa), ya que al coincidir con la activación facilitaría trivialmente la convergencia.

1a) Implementación del Gradiente Descendente (1 punto)

- Implementar el algoritmo del Gradiente Descendente (GD) desde cero para minimizar $J(w, b)$.

1b) Implementación de Adam (2 puntos)

- Implementar el algoritmo de **Adam** paso a paso y desde cero para minimizar $J(w, b)$.
- Utilizar **100 épocas** y 3 diferentes *learning rates*: {**0.1**, **0.01**, **0.001**}.
- Utilizar los **mismos valores iniciales de** w **y** b que se usaron para GD (**IMPORTANTE**).
- Desarrollar 2 variantes del modelo:
  1. Versión **full-batch**.
  2. Versión con **mini-batch** (con *batch size* ≥ 16, a elección).
- **Graficar la función de Costo** $J(w, b)$ **vs. número de época** para comparar la convergencia en ambos modelos con los 3 *learning rates*. Disponer 2 subplots (o 2 gráficos separados): uno para las 3 curvas de Adam *full-batch* y otro para las 3 curvas de Adam *mini-batch*.
- *Nota:* Se permite el uso de librerías como `numpy`, `scipy` y `matplotlib`. No está permitido el uso de PyTorch, TensorFlow u otros frameworks con optimizadores preconstruidos.

1c) Comparativa de optimizadores (0.5 puntos)

- Comparar el resultado y rendimiento de:

  GD vs. **Adam (full-batch)** vs. **Adam (mini-batch)**

  para cada uno de los 3 *learning rates* por separado, utilizando gráficas y tablas comparativas. Se deben generar 3 plots o subplots (uno por *learning rate*), diferenciando cada optimizador por color con su respectiva leyenda.

- **Gráfico del ajuste:** Graficar el dataset original sintético $y(x)$ junto a la función predicha $\hat{y}(x)$ para evaluar si el modelo aprendió el patrón no lineal. Realizar esta comparación en una grilla de **9 subplots** (3 optimizadores $\times$ 3 *learning rates*).
- **Conclusiones analíticas:** Redactar un análisis crítico y detallado que contraste los optimizadores considerando el costo final alcanzado, velocidad de convergencia y estabilidad del entrenamiento.

1d) Visualización en 3D de la trayectoria de aprendizaje (0.5 puntos)

- Graficar en **3D la trayectoria de aprendizaje** de los 3 optimizadores sobre la superficie de la función de costo $J(w, b)$.
- Seleccionar un único *learning rate* (aquel donde mejor se aprecie la diferencia de comportamiento entre métodos).
- Las 3 trayectorias deben graficarse sobre la **misma superficie 3D** y partir estrictamente desde el **mismo punto inicial** (w_0, b_0).
- Se sugiere utilizar `mpl_toolkits.mplot3d` y `np.meshgrid` (opcionalmente animado con `matplotlib.animation` e `IPython.display`).
- Comparar y describir detalladamente la forma en que cada optimizador se desplaza en el espacio de parámetros (w, b) y las diferencias observadas en su dinámica de convergencia.

RECOMENDACIÓN DEL DOCENTE

Se valorará ampliamente que los análisis, explicaciones y conclusiones sean detallados y evidencien un criterio propio de un estudiante de posgrado, evitando respuestas genéricas copiadas de herramientas de IA.
Se recomienda consultar los notebooks guía provistos en el repositorio de la materia, donde se ejemplifica el uso de GD y Adam full-batch para modelos lineales, técnicas de animación 3D y la implementación de versiones en mini-batch.